

Projeto de Compiladores 2021/22

Compilador para a linguagem deiGo

1. Escrita da gramática da linguagem

Separou-se o símbolo Program em duas produções: uma delas terminal e outra que gera um símbolo não terminal Declarations.

O símbolo Declarations pode gerar uma produção VarDeclaration ou uma FuncDeclaration. Mas também existe a possibilidade de gerar ambas e chamar-se recursivamente pela esquerda.

Optou-se por agregar a produção do símbolo VarSpec ao símbolo VarDeclaration, desaparecendo este da gramática. Assim, o VarDeclaration ficou a englobar a combinação das suas produções com as do VarSpec. Por outro lado, para permitir declarações simultâneas de variáveis foi criado o símbolo auxiliar, Aux, que pode gerar uma produção terminal ou produção terminal antecedida de uma chamada recursiva à esquerda.

O símbolo Type não sofreu alterações.

Posteriormente, explicitou-se as produções do símbolo FuncDeclaration.

Na produção Parameters, as declarações simultâneas de parâmetros foram conseguidas através de um símbolo semelhante ao Aux, o Aux2.

O símbolo FuncBody não sofreu alterações.

De seguida, explicitou-se as produções do símbolo VarsAndStatements existentes e adicionou-se uma produção para recuperação local de erros.

No símbolo Statements evidenciamos as produções que originam if's, as produções que originam for's, as produções de return e as produções de print. Por motivos de implementação posterior da árvore acabamos por acrescentar uma produção que deriva do símbolo FuncInvocation diretamente no Statement. Posteriormente, foi utilizada uma produção com recursividade à esquerda para gerar produções Statement encadeadas, esta produção, Aux4, possui duas produções de recuperação local de erros, uma delas terminal e outra que permite intercalar com outros Statements ou erros.

Em contrapartida, para o símbolo ParseArgs adicionou-se uma produção de recuperação local de erros.

Para o símbolo `FuncInvocation` adicionou-se uma produção de recuperação local de erros e retirou-se a produção anteriormente mencionada, que passou a produção direta da produção `Statement`.

No caso do símbolo `Expr` explicitou-se as produções existentes, adicionou-se uma produção de recuperação local de erros e acrescentou-se a produção proveniente da produção `FuncInvocation`. Para permitir uma sucessão de símbolos `Expr` recorreu-se a uma produção de lógica congruente com o `Aux`, o `Aux3`.

2. Algoritmos e estruturas de dados utilizados na AST e na tabela de símbolos

Optámos por uma árvore implementada através de vetores. Cada estrutura `ast_node_t` é composta por um `const char * id` que permite distinguir os nós, por um `const char * type` que será utilizado para guardar o tipo do nó resultante da análise semântica, um `int temp` que será utilizado posteriormente na geração de código, um `vector_t * children` onde serão guardados os nós filhos e um `token_t * token` onde serão guardadas informações sobre os tokens. Deste modo, foi construído a função `add_child` que adiciona um nó ao vetor `children`. Por sua vez a função `add_as_siblings` tem como parâmetros dois nós, `parent` e `node`, e tem como objetivo eliminar o nó `node`, passando os seus filhos a filhos do `parent`.

A estrutura `vector_t` é constituída por um `int size` que indica o número de elementos que o vetor contém, o `int capacity` que indica o número máximo de elementos do vetor e `void ** data` que contém os filhos do nó. Para este último, optou-se por um ponteiro `void` para reaproveitar a estrutura. O vetor é redimensionado conforme a necessidade pela função de inserção `push_back`, ou seja, se o `size` igualar a `capacity`, esta é duplicada e a `data` realocada, sendo o elemento inserido.

A estrutura `token_t` é constituída por um `char * value` que contém informação particular ao token, `int column` e `int line`, que indicam a posição do token utilizada na impressão de erros.

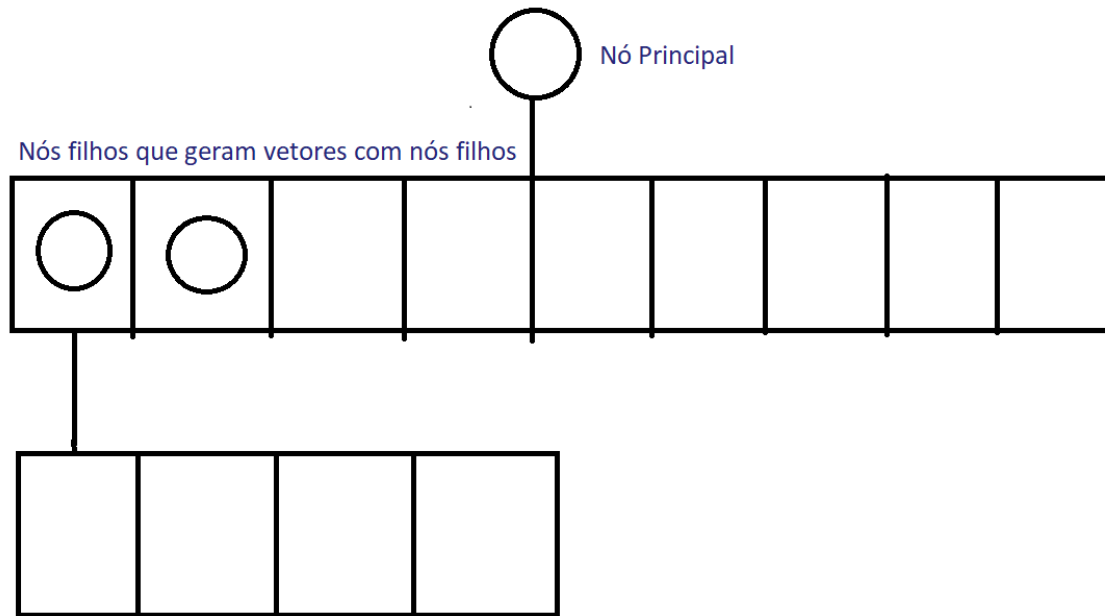
Para a tabela de símbolos utilizou-se um vetor, `symbol_table`, que armazena estruturas `symbol_table_t` e essas por sua vez contém estruturas `symbol_t` que representam os símbolos do programa.

A estrutura `symbol_table_t` contém um `char * id` que permite identificar as funções ou variáveis globais, um `int is_defined` que é uma flag para o controlo das definições de funções, um vetor, `symbols`, com os símbolos e um vetor de parâmetros no caso de ser uma função.

A estrutura `symbol_t` tem um `char * id`, para identificação, os `int is_param`, `int is_func` e `int is_used` que são flags para a deteção de erros, um `vector_t parameters` para simplificar a impressão na AST anotada, um `char * type` para anotar o tipo e um `int temp` para guardar o registo na geração de código.

O algoritmo percorria a árvore recursivamente sendo que alguns dos nós eram tratados iterativamente, nomeadamente, nós com número e posição dos filhos bem definida.

A imagem seguinte demonstra a estrutura da árvore implementada:



3. Geração de Código LLVM

Inicialmente a função `generate_llvm` começa por declarar as funções `printf`, `atoi` e constantes para imprimir os literais.

Seguidamente através da função `declare_const_str` recorre-se a uma primeira passagem recursiva na AST para declarar as constantes literais.

Posteriormente é efetuada uma passagem pelos nós declarativos e são declaradas funções e variáveis globais. Nas declarações, a função `main` é sempre gerada com os parâmetros `argc` e `argv` para permitir a utilização de parâmetros passados à função através da linha de comandos. Ao mesmo tempo, as variáveis são sempre inicializadas com valores default.

No corpo das funções percorre-se os nós e entra-se nas funções criadas para cada tipo de nó.

Na declaração de variáveis é alocada memória e os valores inicializados com o default, sendo o registo temporário guardado.

No `assign` procura-se a variável local e globalmente, utilizando-se a instrução `store` diretamente se for um literal ou desenvolvendo-se a expressão, sendo o seu resultado final guardado no registo da variável.

Desenvolveu-se expressões a partir de uma função recursiva que começa a avaliação pelos símbolos terminais e realiza cada operação guardando o seu valor na variável `temp` do nó. Os literais eram guardados recorrendo a uma operação de `add` para que todos os eles guardassem os valores e não ponteiros.

Ao longo das restantes funções foi utilizada a técnica de percorrer inicialmente a tabela de símbolos local, se não houver correspondência efetua-se uma segunda procura pela tabela de símbolos global, carregando-se o seu valor que posteriormente irá ser utilizado nas diversas operações.

Nas funções que geram if's é feita a comparação com a expressão e intercala-se a criação dos labels com a chamada da função que irá criar o corpo da mesma, assim irá ser permitido o encadeamento de if's.

Seguindo a mesma técnica utilizada nos if's foi criada a função que gera os for's.

Ao longo do código foram utilizadas funções auxiliares: para gerar o tipo de dados característicos do llvm, gerar os valores de default do mesmo, contar o número de caracteres normais, contar o número de caracteres de escape e imprimir os floats.

Inês Martins Marçal 2019215917

Noémia Quintano Mora Gonçalves 2019219433